



CENTRO UNIVERSITÁRIO DE BRASÍLIA FACULDADE DE TECNOLOGIA E CIÊNCIAS
SOCIAIS APLICADAS CURSO DE CIÊNCIA DA COMPUTAÇÃO

PROJETO INTEGRADOR 1
ORIENTADOR: KADIDJA VALÉRIA
DOCUMENTO GERAL - FlowUP

Eduardo Fernandes - 22552011

Rafael Spillari - 22407376

Kaio Matozo - 22309172

Marco Túlio Ferreira - 22401968

BRASÍLIA, Abril 2026

Documentação de Fonte de Dados, ETL e Arquivos Gerados

1. Fonte dos Dados

1.1 Identificação do Dataset

O dataset utilizado neste projeto é proveniente de uma pesquisa acadêmica publicada na plataforma Figshare, repositório de dados científicos abertos. Trata-se de um survey aplicado a estudantes e profissionais de design no Reino Unido, com foco na frequência e nos fatores influenciadores da procrastinação durante o processo de design.

Título	SPSS processed data set of Procrastination survey data
Autores	Ruth Welsh, George Torrens, Simon Downs, Jasmine Rose May Swalwell, Salman Asghar, Yi Wang
Publicação	3 de setembro de 2024
Plataforma	Figshare (repositório de dados científicos abertos)

URL	https://figshare.com/articles/dataset/SPSS_processed_data_set
Licença	Creative Commons — dados de uso livre para fins de pesquisa
Formato original	SPSS (.sav) — formato nativo do software IBM SPSS Statistics

1.2 Contexto da Coleta

A pesquisa foi conduzida em uma escola de design e artes criativas do Reino Unido entre janeiro de 2022 e agosto de 2024. O objetivo era compreender como estudantes e profissionais de design experienciam a procrastinação nas diferentes etapas do processo criativo — desde revisão de literatura até prototipagem física.

Os dados foram coletados por meio de questionário estruturado aplicado a 155 participantes, sendo 146 estudantes e 9 membros da equipe de staff da instituição. O instrumento capturou informações demográficas, condições de saúde autodeclaradas, frequência de procrastinação em tarefas específicas, comportamentos de escape e fatores desencadeadores.

1.3 Relevância para o Projeto FlowUP

Embora o dataset tenha sido coletado em uma escola de design britânica, sua estrutura é altamente compatível com os objetivos do FlowUP. Os dados reais de survey permitem análises sobre:

- Quais tarefas acadêmicas são mais procrastinadas (relatórios, prototipagem, ideação etc.)
- Quais comportamentos os participantes adotam ao procrastinar (TV, redes sociais, dormir etc.)
- Quais fatores cognitivos e emocionais deflagram a procrastinação (tédio, dificuldade, falta de confiança etc.)
- A relação entre condições de saúde mental (ansiedade, depressão, ADHD) e o score de procrastinação
- Diferenças por gênero, faixa etária e nível de experiência

O uso de dados reais — em vez de dados sintéticos — garante validade externa às análises e fortalece a credibilidade acadêmica do projeto.

2. O Processo ETL

2.1 O que é um arquivo .sav?

O formato .sav é o formato nativo do IBM SPSS Statistics, um dos softwares de análise estatística mais utilizados em pesquisas acadêmicas nas áreas de ciências sociais,

psicologia e educação. Diferente de um simples CSV, o arquivo .sav armazena não apenas os dados, mas também metadados ricos:

- Rótulos de variáveis: nome descritivo de cada coluna (ex: "Gender" → "Gênero do participante")
- Rótulos de valores: mapeamento de códigos numéricos para texto (ex: 1 → "Female", 2 → "Male")
- Tipos de dados e escalas de medição (nominal, ordinal, escala)
- Metadados de encoding e versão do arquivo

Isso significa que ao abrir um .sav sem o SPSS, os dados aparecem como números sem significado. O ETL foi desenvolvido para resolver esse problema, convertendo os códigos em rótulos legíveis e exportando o resultado em formatos universalmente acessíveis.

2.2 Fluxo do ETL

O processo ETL foi implementado em Python e executado em cinco etapas sequenciais:

Etapa	Operação	Tecnologia
1 — Extract	Leitura do arquivo .sav com metadados completos	pyreadstat
2 — Transform	Aplicação dos rótulos textuais nos valores codificados	pyreadstat + pandas
3 — Transform	Geração do codebook (dicionário de variáveis)	pyreadstat + pandas
4 — Transform	Limpeza, curadoria de colunas e renomeação para português	pandas
5 — Load	Exportação dos dados finais em CSV e Excel	pandas + openpyxl

2.3 Dependências Utilizadas

- pyreadstat: biblioteca Python especializada na leitura de formatos estatísticos (.sav, .dta, .sas7bdat). Responsável por decodificar tanto os dados quanto os metadados do arquivo SPSS.
- pandas: framework principal para manipulação tabular dos dados — limpeza, normalização de nomes de colunas, curadoria e exportação.
- openpyxl: motor de escrita para arquivos .xlsx, permitindo a criação de múltiplas abas e formatação automática de colunas no Excel.

2.4 Detalhes das Transformações Aplicadas

Etapa 2 — Aplicação de rótulos de valores

Como o argumento `apply_value_labels` apresentou incompatibilidade em alguns ambientes, os rótulos foram aplicados manualmente via mapeamento Python. Para cada coluna com dicionário de valores (`variable_value_labels`), os códigos numéricos foram substituídos pelos rótulos textuais correspondentes. Valores sem rótulo foram mantidos como originalmente registrados.

Etapa 3 — Geração do codebook

O codebook é extraído diretamente dos metadados SPSS e documenta o rótulo descritivo e os valores possíveis de cada uma das 46 variáveis originais. Ele é exportado tanto como aba no Excel quanto como CSV separado, servindo como referência permanente mesmo após a curadoria remover algumas colunas dos dados principais.

Etapa 4 — Limpeza, curadoria e renomeação

Esta é a etapa mais importante para a qualidade do dashboard. Ela é dividida em três sub-passos: limpeza básica (remoção de linhas/colunas completamente vazias e normalização de nomes), curadoria de colunas (remoção de variáveis desnecessárias — detalhada na seção 3) e renomeação para português com prefixos semânticos. O detalhamento completo das decisões de curadoria está na seção 3 deste documento.

3. Curadoria de Colunas — Decisões e Justificativas

O dataset original possui 46 colunas. Para um dashboard de alto nível focado em insights sobre procrastinação, muitas dessas colunas são redundantes, têm variação nula, possuem preenchimento insuficiente ou estão fora do escopo analítico do FlowUP. A etapa de curadoria reduziu o dataset de 46 para 39 colunas, removendo 7 variáveis.

Todas as decisões foram documentadas no próprio código-fonte (dicionário COLUNAS_REMOVIDAS) para garantir rastreabilidade e reprodutibilidade do ETL.

3.1 Resumo das Remoções

Colunas originais	Colunas removidas	Colunas finais	Redução
46	7	39	15,2%

3.2 Detalhamento de cada remoção

Coluna removida	Motivo	Justificativa detalhada
condition	Redundante	String concatenada (ex: "Dyslexia,ADHD") gerada pelo SPSS para leitura humana. No dashboard, as flags individuais (dislexia, tdah, ansiedade...) permitem filtros e agrupamentos precisos. Manter as duas seria pura duplicidade de informação.
dysclcula	Constante	Dyscalculia tem valor "No" em todos os 155 registros. Uma coluna constante é estatisticamente inerte — não agrega nenhuma informação analítica ao dashboard e causa confusão em quem analisa os dados.
other_condition	Texto livre	Campo aberto preenchido por apenas 14 de 155 participantes (9%). O conteúdo é heterogêneo e não estruturado ("Autism", "OCD", "I don't know"),

		inviabilizando agrupamentos úteis sem processamento de linguagem natural (NLP), fora do escopo deste projeto.
what_should_do	Meta-cognição	Mede com que frequência o participante fala sobre o que deveria fazer — comportamento de autorregulação, não de fuga. Misturar meta-cognição com comportamentos de escape (TV, redes sociais, dormir) causaria confusão conceitual nos gráficos do dashboard.
plan_what_should_do	Meta-cognição	Análogo ao anterior: mede planejamento do que deveria ser feito. Comportamento de autorregulação fora do foco do dashboard, que prioriza comportamentos de escape e gatilhos emocionais.
brand_analysis	Específica de design	Análise de marcas é atividade típica de cursos de design industrial britânico sem equivalente direto no contexto de Ciência da Computação do CEUB. As tarefas mantidas (relatório, documentos, ideação, prototipagem) são suficientemente representativas.
ergonomic_evaluation	Específica de design	Avaliação ergonômica é igualmente específica do contexto de design industrial e não se aplica ao perfil dos usuários do FlowUP. Removida para evitar distorção dos dados de tarefas procrastinadas.
technology_review	Específica de design	Revisão tecnológica de produtos de design físico não tem equivalente no contexto universitário geral. Com a remoção, a categoria de tarefas do dashboard torna-se mais generalizável e relevante.

3.3 Renomeação e Organização Semântica

As 39 colunas mantidas foram renomeadas para português e organizadas por prefixos semânticos, facilitando a criação de grupos de campos no Power BI e a leitura dos gráficos pelo público-alvo:

Prefixo	Quantidade de colunas	O que representa
(sem prefixo)	11	Dados demográficos e perfil do participante
tarefa_*	7	Frequência de procrastinação por tipo de tarefa acadêmica
fuga_*	9	Comportamentos adotados ao procrastinar (TV, dormir, socializar etc.)
gatilho_*	10	Fatores cognitivos/emocionais que deflagram a procrastinação
score_*	1	Pontuação composta de procrastinação (7–66)
TOTAL	39	—

3.4 Colunas Mantidas — Visão Completa

Nome final (português)	Grupo	Descrição
genero	Perfil	Gênero: Feminino, Masculino, Não-binário
faixa_etaria	Perfil	Faixa etária: de 18-19 até 56-65 anos
sem_condicao_saude	Perfil	Não possui condição de saúde (Sim/Não)
dislexia	Perfil	Possui dislexia (Sim/Não)
dispraxia	Perfil	Possui dispraxia (Sim/Não)
tdah	Perfil	Possui TDAH (Sim/Não)
ansiedade	Perfil	Possui ansiedade (Sim/Não)
depressao	Perfil	Possui depressão (Sim/Não)
outra_condicao	Perfil	Possui outra condição de saúde (Sim/Não)
papel_atual	Perfil	Estudante, trabalhador ou outro
anos_experiencia	Perfil	De menos de 1 ano até mais de 10 anos
tarefa_revisao_literatura	Tarefas	Frequência de procrastinação em revisão bibliográfica
tarefa_ideacao	Tarefas	Frequência de procrastinação em ideação criativa
tarefa_decisao_design	Tarefas	Frequência de procrastinação em decisões de projeto
tarefa_prototipagem_digital	Tarefas	Frequência de procrastinação em prototipagem digital
tarefa_prototipagem_fisica	Tarefas	Frequência de procrastinação em prototipagem física
tarefa_escrita_relatorio	Tarefas	Frequência de procrastinação em escrita de relatórios
tarefa_completar_documentos	Tarefas	Frequência de procrastinação em completar documentos
fuga_ao_faz_nada	Fugas	Frequência de não fazer nada ao procrastinar
fuga_dormir	Fugas	Frequência de dormir ao procrastinar
fuga_tv_filmes	Fugas	Frequência de assistir TV/filmes ao procrastinar
fuga_comer_beber	Fugas	Frequência de comer ou beber ao procrastinar
fuga_conversar_amigos	Fugas	Frequência de conversar com amigos ao procrastinar
fuga_socializar	Fugas	Frequência de socializar ao procrastinar
fuga_caminhar_exercitar	Fugas	Frequência de caminhar/se exercitar ao procrastinar
fuga_arrumar_quarto	Fugas	Frequência de arrumar o ambiente ao procrastinar

fuga_outra_tarefa_menos_importante	Fugas	Frequência de fazer outra tarefa menos importante
gatilho_distracao_tv_amigos_redes	Gatilhos	Efeito: distração por TV, amigos ou redes sociais
gatilho_distracao_novos_projetos	Gatilhos	Efeito: distração por novos projetos interessantes
gatilho_importancia_tarefa	Gatilhos	Efeito: percepção de importância da tarefa (nota/dinheiro)
gatilho_prazo_iminente	Gatilhos	Efeito: proximidade do prazo de entrega
gatilho_muitas_tarefas	Gatilhos	Efeito: excesso de tarefas simultâneas
gatilho_nao_gosta_tarefa	Gatilhos	Efeito: não gostar da tarefa
gatilho_tedio_sem_interesse	Gatilhos	Efeito: tédio e falta de interesse
gatilho_nao_entende_motivo	Gatilhos	Efeito: não compreender o propósito da tarefa
gatilho_tarefa_dificil_lenta	Gatilhos	Efeito: dificuldade ou lentidão da tarefa
gatilho_falta_confianca	Gatilhos	Efeito: falta de confiança para completar a tarefa
score_procrastinacao	Score	Pontuação composta (7–66), calculada no SPSS original

4. Arquivos Gerados

O processo ETL produziu três arquivos de saída. A seguir, cada um é descrito em detalhes.

4.1 procrastination_clean.csv

Tipo: CSV com encoding UTF-8 com BOM — 155 linhas × 39 colunas

Arquivo principal com todos os dados tratados e curados. Valores numéricos foram convertidos para rótulos textuais, colunas desnecessárias foram removidas, nomes foram traduzidos para português e o encoding garante compatibilidade com Excel e Power BI.

Atributo	Valor
Total de respondentes	155
Total de colunas (após curadoria)	39
Colunas removidas na curadoria	7 (de 46 originais)
Score médio de procrastinação	47,5 de 66
Score mínimo / máximo	7 / 66
Encoding	UTF-8 com BOM (utf-8-sig)

4.2 procrastination_clean.xlsx

Tipo: Planilha Excel com duas abas

- Aba "Dados": mesmos 155 registros × 39 colunas do CSV, com formatação automática de largura de colunas.
- Aba "Codebook": dicionário completo das 46 variáveis originais (antes da curadoria), com rótulos SPSS e valores possíveis — essencial para rastreabilidade.

4.3 codebook.csv

Tipo: CSV — dicionário de variáveis do dataset original

Documenta as 46 variáveis originais do SPSS com três colunas: variavel (nome no SPSS), rotulo (descrição completa) e valores_possiveis (mapeamento de códigos para rótulos). Serve como referência permanente mesmo após a curadoria ter removido 7 colunas dos dados principais.

5. Observações e Limitações

5.1 Valores Ausentes

O dataset apresenta valores ausentes em diversas colunas, o que é esperado em surveys autodeclaratórios. As colunas com maior volume de dados ausentes são:

- score_procrastinacao: 49 ausentes (31,6%) — participantes que não completaram todas as questões da escala
- gatilho_prazo_iminente: 30 ausentes — campo com maior taxa de não resposta entre os gatilhos
- gatilho_importancia_tarefa: 24 ausentes

Para análises no dashboard, recomenda-se filtrar apenas os registros com score válido (106 respondentes) ou tratar os ausentes por imputação simples (média/moda) dependendo da variável.

5.2 Especificidade da Amostra

Os dados foram coletados exclusivamente em uma escola de design e artes criativas do Reino Unido. As tarefas específicas de design removidas na curadoria (brand_analysis, ergonomic_evaluation, technology_review) já não estão presentes no dataset final. As demais variáveis — comportamentos de fuga, gatilhos emocionais e condições de saúde — são amplamente generalizáveis à experiência universitária independente do curso.

5.3 Período de Coleta

Os dados foram coletados entre janeiro de 2022 e agosto de 2024, abrangendo parte do período pós-pandemia, quando questões de saúde mental entre estudantes estavam

particularmente elevadas. Isso pode influenciar a prevalência de ansiedade (31,6%) e depressão (20,6%) na amostra.

6. Como Usar os Dados

6.1 Importação no Power BI

- Abrir o Power BI Desktop
- Selecionar "Obter Dados" → "Texto/CSV"
- Selecionar o arquivo procrastination_clean.csv
- Verificar se o encoding foi detectado como UTF-8
- Clicar em "Carregar" ou "Transformar Dados" para ajustes adicionais no Power Query

6.2 Importação no Excel / Google Sheets

Basta abrir diretamente o arquivo procrastination_clean.xlsx. A aba "Dados" contém os dados prontos para uso com nomes em português, e a aba "Codebook" serve como referência para interpretação das colunas originais.

6.3 Sugestões de visuais para o dashboard

Visual	Colunas sugeridas	Insight esperado
Gráfico de barras	task_* (frequência)	Quais tarefas são mais procrastinadas
Gráfico de barras	escape_* (frequência)	O que as pessoas fazem ao procrastinar
Gráfico de pizza	trigger_* (tipo de reação)	Proporção entre "foge" e "desiste"
Histograma	score_procrastinacao	Distribuição dos scores na amostra
Box plot / barras	score por ansiedade/depressao/tdah	Impacto da saúde mental no score
Heatmap ou tabela	score por faixa_etaria + genero	Diferenças demográficas na procrastinação

6.4 Uso em Python para análise adicional

```
import pandas as pd
df = pd.read_csv('procrastination_clean.csv')
```

```
codebook = pd.read_csv('codebook.csv')

# Filtrar apenas respondentes com score válido (106 registros)
df_valido = df.dropna(subset=['score_procrastinacao'])

# Ver distribuição dos scores por condição de saúde
df_valido.groupby('ansiedade')['score_procrastinacao'].mean()
```

Referências

Welsh, R., Torrens, G., Downs, S., Swalwell, J. R. M., Asghar, S., & Wang, Y. (2024). SPSS processed data set of Procrastination survey data. Figshare.
https://figshare.com/articles/dataset/SPSS_processed_data_set_of_Procrastination_survey_data/26871157

McKinney, W. (2022). pandas: Powerful data analysis tools for Python.
<https://pandas.pydata.org>

Haghish, E. F. (2020). pyreadstat: Read and write SAS, SPSS and Stata files from Python.
<https://pypi.org/project/pyreadstat>